HeavyHeader

反事实构建实验：
可验证的 C/C++ 头文件成本治理

项目选题报告

作者：王子周

日期：2026 年 10 月 19 日

申报赛道：第四届开放原子大赛·2026 开源行业解决方案创新赛 · 赛道一（开源基础软件与解决方案）

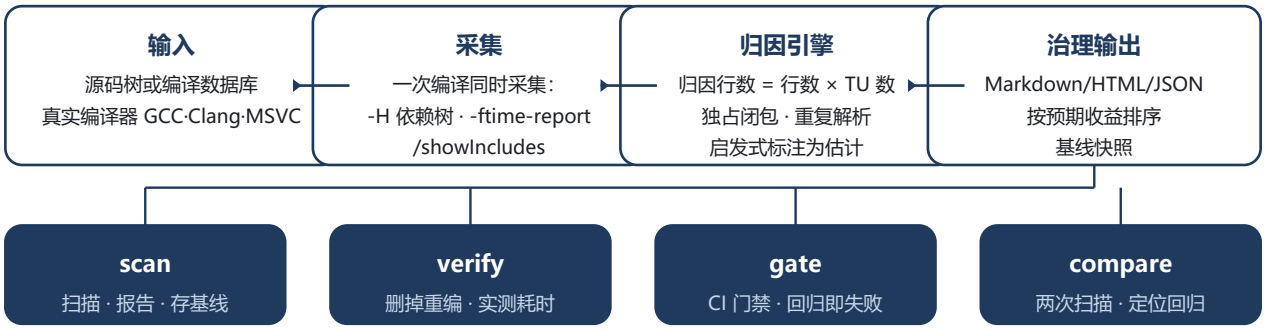


图 1 HeavyHeader 工作链。工具不自己解析 C++，而是向真实编译器提问并读取它的回答，把编译器的真实计时数据与依赖图交叉归因，再交给命令消费（当前共十三个命令）。图中各环节均已实现并有测试覆盖。

摘要

大型 C/C++ 工程的构建时间是真实的成本：一次全量构建动辄数十分钟到数小时，CI 集群机时与工程师的等待时间都花在里面。而构建慢的最大单一来源，往往不是算法，而是头文件失控——一个被大量编译单元传递包含的重量级头文件，会让整个项目反复为它付费。现有工具分别解决了其中一段：Header Hero（Bitsquid，2011）用「行数 × 包含次数」给出成本排序，本文的归因公式即来自它；ClangBuildAnalyzer 用 -ftime-trace 给出逐头文件累计毫秒；IncludeGuardian 给出结构建议；deheader 注释掉一条 include 再编译来验证可删性。但它们都不回答「删掉这一条，这次构建具体省多少时间、内存和体积」，因此治理工作缺少量化依据，也无法在 CI 里按实测净收益防止成本回归。

HeavyHeader 是一个 Python 实现的命令行平台，核心设计只有一条主线：不自己解析 C++。它向真实编译器提问——GCC/Clang 的 `-H` 依赖树与 `-ftime-report` 分阶段计时、MSVC 的 `/showIncludes`——并把编译器的真实输出与依赖图交叉归因。基础指标「归因行数」定义为一个头文件的行数乘以引用它的编译单元数，衡量整个项目为它付出了多少行解析量；在此之上给出独占闭包（删掉某条 include 后真正会停止被解析的集合）、缺少 include guard 的重复解析检测、模板实例化成本与可选的前向声明建议。

本项目把自己做的事命名为反事实构建实验（Counterfactual Build Experiment）：工具的输出单位不是一份排序或一张清单，而是一次受控实验的结论——候选由独占闭包按边际收益选出，收益由会话内噪声线 + 交替 A/B 实测越过才成立，最终以「建议删除 / 保留 / 需人工判断」三态交付，每条附三维度证据与复现命令。「组合现成工具」与「方法论创新」的界线是可消融的：拿掉其中任何一层，都有实测记录在案的错误结论在等着（拿掉交替测量，2.005% 的机器漂移会被报成收益；拿掉复测，第一轮 4 条 improved 复测 0/4 复现）。完整论证见仓库 `docs/innovation.md`。

十三个命令构成完整治理闭环：`scan` 产出 Markdown / HTML / JSON 报告并可存为基线；`verify` 把候选 include 真的注释掉、重新编译、实测耗时/内存/体积差异——成本模型再严谨也仍是模型，权威结论来自实测；`gate` 在 CI 中对基线做回归判定，失败时指名道姓报出是哪些头文件、哪些 include 行引入的；`compare` 对比两份扫描，定位成本上升的具体文件；`toolchains` 给出同一份代码在多编译器下的成本横评；`history` 把多次扫描聚合成成本趋势；`pr-comment` 把对比渲染成 PR 评论并幂等发布；`blame` 把成本回归归因到具体 commit 与 include 行；`edge-cost` 按 include 边给出边际解析成本；`configs` 让同一棵树按多套构建配置各扫一遍、只报判定变了的候选；`verified` 只列编译器证据撑住的候选（汇编一致 + 省时过线 + 复测成立）。门禁只使用确定性的归因行数判定，墙钟时间因随负载波动只做展示。

项目已完成 v0.1–v0.4 全部路线图条目，通过 725 个单元测试，CI 覆盖三大操作系统 × 四个 Python 版本的测试矩阵、lint、自举扫描、覆盖率与 MSVC 证据共 16 个岗位（2026-10-27 核实最新提交 239f85b：CI 14 个岗位全绿，含 macOS 4 组）；运行时零第三方依赖并由测试守护，v0.1.0 已发布至 PyPI（2026-10-19，全新虚拟环境 安装验证通过）。四个真实开源项目（fmt、nlohmann-json、spdlog、cpp-httplib）的基准显示：54 个成功编译单元合计 1,430 万行头文件解析量、104 个成本候选；单体头 httplib.h 一项即被归因42 万行解析量，是最极端的成本热点样

本。候选清单包含每一条直接 include——系统头与第三方头照常进入统计与建议清单；删除动作发生在项目自己的源文件里，「删掉 #include <iostream>」是完全正常的改动。早先版本把系统头整体排除在候选之外，结果恰好把全部有效改动挡在门外（对照实验里 5/5 个真实改动都是这一类）；头文件来源（HeaderKind）现在只是给读者看的标签，不是过滤器。所有基准数据可由一条 命令复现，失败的编译单元被如实报告而不被跳过。同一份构造工程还已在 GCC / Clang / MSVC 三套真实编译器上跑通横评：三者对项目头的归因行数完全一致（44），差异只落在系统头解析量与耗时上——这正好印证了成本归因与工具链无关，也是「结构指标确定性」的直接证据。

关键词：C/C++；构建效能；头文件依赖；成本归因；编译器计时；持续集成门禁

评审关注点导览

评审项（权重）	本报告对应章节	一句话答案
技术创新（30%）	二（范式与首版边界）、三（实测协议）、四（归因方法学）	反事实构建实验 + 成本考古 / 边级归因两项新增能力；候选判定经四轮精度迭代，三个语料零假阳性；每层创新都有消融证据
场景落地（30%）	三（四道门槛）、五（真实项目基准）、九（完整构建实测）、十一（上游 PR）	scan → verify → gate 接成流水线；63 TU 完整构建 −11.4% CPU、断言逐个一致；两条实测优化已提交上游（doctest#1212、zlib#1344）；spdlog 上 −78% 的大额「提升」被汇编闸门识破为静默改程序
开源治理（20%）	六（门禁与治理流程）、七（诚实的边界）、十（已有基础）	GOVERNANCE + 零依赖守护测试 + 语义化版本发布；v0.1.0 已发布至 PyPI 并通过全新环境安装验证；CI 16 岗位（2026-10-22 核实：最新提交 CI 14 个岗位全绿，含 macOS 4 组）
长期发展（20%）	十（开发起点）、十二（路线图与治理）	v0.1–v0.4 已交付、v0.5 生态集成进行中（PyPI 已上架）；贡献者阶梯与基金会孵化路径写在 GOVERNANCE.md

本报告只讲一条主线：发现成本热点 → 提出删除候选 → 用真实编译器验证（删掉、重编、比汇编）→ 重复测量收益 → 生成可审查补丁 → 把成本回归接进 CI 门禁。候选发现不是本项目独创（ClangBuildAnalyzer 等已成熟）；工程力量集中在后三段——反事实验证与回归治理。例如 spdlog 上一条 −78% 的大额计时「提升」，经汇编指纹比对实为删掉公共 API 的实现，被验证环节拦下；doctest 与zlib 各一条 −3.0% / −2.1% 的优化则走完主线并成为上游 PR（doctest#1212、madler/zlib#1344；状态经 2026-10-21 核实均为 open、未被合并，本文只写「已提交」不写「已被采用」）。四语料 100 个编译单元的核心指标：**约 4.5 秒分析换 1 条已证实候选**（编译通过 + 真少解析文件 + 代码生成一致）。

目录

一 问题背景与需求依据 5
二 平台方案与首版边界 6
三 从扫描到门禁的完整任务 6
四 成本归因如何保持准确 8
五 真实项目基准 9
六 CI 门禁与治理流程 11
七 诚实的边界 12
八 报告与可复现 13
九 技术路线与模块分工 13
十 已有基础与开发起点 14
十一 同类工具与项目价值 15
十二 团队协作与后续开发 16
参考资料 17

一 问题背景与需求依据

构建时间是真实的成本

C/C++ 项目的构建管线里，编译器在每个编译单元上都要重新解析一遍它 include 到的头文件。一个被几万个编译单元传递包含的重量级头文件，会让整个项目反复为同一份文本付费；而这样的头文件往往来自无意的聚合包含、复制粘贴的样板 include，或历史遗留的「保险起见都带上」。构建变慢之后，团队的典型反应是加机器、上缓存（ccache / distcc），这些手段缓解但不消除根因：头文件解析量还在那里，只是被分摊到了更多核与更多命中上。

现有工具回答的是另一个问题

围绕 include 治理已有不少工具，而且比想象中密：成本排序、逐头文件耗时、结构建议、注释后重编各有人做。下表按「答到哪一句为止」逐项核对——事实核实日期与逐格证据等级见仓库 docs/competitors.md 与 docs/competitor-matrix.md。

工具	能做什么	不能做什么
Header Hero（2011）	谁可能贵：行数 × 被包含次数的成本排序	只排序；正则解析漏宏；不验证、不量化删后收益
ClangBuildAnalyzer	现在谁花了多少：逐头文件累计 ms	只描述现状；仅 Clang；无基线、无门禁
CompileScore	同一数据源 + VS 内可视化（TU 时间线、includers 图）	无反事实、无决策；Windows / VS 为主
MSVC Build Insights	MSVC 侧官方答案：include 树、PCH 建议	删后量化、三态结论、按净收益的门禁均不提供
IncludeGuardian	该改什么结构：七类建议	不编译、不实测（token 口径估算）
deheader（2010）	删了还能编吗：注释掉再编译	二值结论，不量化收益
IWYU / clang-include-cleaner	该不该包含：AST 级必需性判定	不给成本量化，无法排序优先级
Include-Wrangler / clang-build-profiler / include-what-costs	按边数文件、呈现逐边耗时、逐头实测	分别停在文件数 / 呈现 / 节点级，都不算「删了省多少」
HeavyHeader（本项目）	删了的净收益是多少、有多大把握	重载决议选中的模板依赖（AST 区）文本层无信号，由 verify 实测兜底

缺少成本量化的直接后果是：治理工作没有优先级——几百条 include 里先动哪一条？删错一条省不了一秒，删对一条可能省掉百分之几十；同时治理成果无法沉淀为约束——今天清干净的头文件，明天一个 PR 又把它拖回原样，没有门禁守着。本课题据此把「成本归因 + 实测验证 + 门禁防回归」作为需要同时交付的三件事。出处与复核清单见 R1–R16。

面向的用户与代表任务

平台首先面向维护中大型 C/C++ 工程的开发者与构建工程师（Build / Infrastructure 角色），代表任务是：在不破坏构建的前提下，找出让全量构建变慢的头文件，按预期收益排序精简，然后在 CI 中固化成果。输入是源码树（或编译数据库 compile_commands.json）与编译器；输出是按预期收益排序的精简清单、可复现的基准数据，以及一个能在流水线里执行的门禁命令。该任务是首版的需求假设，实际收益通过同任务工具对照与目标用户试用检验。[D1]

二 平台方案与首版边界

一条完整的工作链

工作链从源码树开始：工具发现编译单元（优先采用 compile_commands.json 中的编译命令，否则递归查找源文件并按命令行参数构造），并行调用真实编译器采集依赖树与分阶段计时，在归因引擎里计算每条 include 的成本，最后由命令消费同一份数据——扫描报告、实测验证、门禁判定与两次扫描对比。四路输出共享同一套模型与指标定义，不存在两套数字。[D2]

首版包含的完整范围

首版（v0.1）交付：归因行数、独占闭包、重复解析检测三类确定性归因；模板实例化成本归因（每个编译单元精确、按头文件为启发式）；预编译头收益估算（--pch）与前向声明建议（--forward-decl）两个可选分析；Markdown / 自包含单文件 HTML / JSON 三种报告格式；基线存储与 CI 门禁；以及覆盖四个真实开源项目、一键可复现的基准套件。

编译器	依赖树来源	分阶段计时来源
GCC 9+	-H	-ftime-report
Clang 17+	-H	-ftime-report
MSVC	/showIncludes	墙钟计时（MSVC 无等价的文本格式）

有 compile_commands.json 时严格按其中的 flags 编译——否则同一份代码在不同 flags 下的数字没有可比性。R1：GCC 预处理输出文档 R2：GCC 调试选项文档 R3：MSVC /showIncludes 文档

刻意不做的事

精确判定 include 是否被语义上使用需要 libclang 级别的 AST 分析，那会把使用门槛抬到需要一整套 LLVM 工具链，并破坏「无第三方运行时依赖、Python 3.10+ 即可安装」的部署约束。本课题刻意把精确模式排在后续版本（v0.3）且作为可选依赖，默认路径保持零依赖、能在最朴素的 CI 容器里跑起来。这个取舍与它的理由写在路线图里，不藏在脚注中。[D4]

三 从扫描到门禁的完整任务

扫描与报告

一次典型扫描的终端输出与报告生成：

```
$ heavyheader scan ./src --format html -o report.html
2 TU · 425 条依赖边 · 206,100 行头文件解析量 · 5 个成本候选（其中 1 个疑似未使用）
```

报告按预期收益排序给出成本候选，每个候选标注发现类别与证据——「缺少 include guard」是确定性信号，「疑似未使用」是启发式估计，两者在报告里有明确区分，绝不混排。

实测验证：模型让位于实测

```
## lonely.h <- main.cpp
状态：improved — 基线 520 ms -> 移除后 320 ms
实测节省：200 ms (38.5%)

## core.h <- util.cpp
状态：compile-error — 移除后编译失败：util.cpp:3:14: error: 'Core' was not declared
```

verify 把候选 include 注释掉（不是删除——实验必须可逆）、在临时目录用完全相同的 flags 重新编译、每侧重复 N 次取最小值。编译失败同样是被记录的结果，不会被静默丢弃：它说明这条 include 是必需的，这本身就是有价值的治理结论。

明确结论：每个候选一个「值不值得删」

启发式回答「这个头还用不用」，是个可能性问题；开发者问的是「这行值不值得删」，是个决策问题。决策层（attrib/advice.py）把探针证据收敛成三个明确结论之一，规则是确定性纯函数：建议删除（编译通过且耗时下降超过 2% 噪声线）、保留（编译器已否决，不必再试）、需人工判断（编译可行但收益在噪声内，附倾向与理由）。未实测的候选显示「未实测」——没测过就不下判断。每个结论按功能影响、维护成本、构建体验三个维度列依据，实测数据覆盖编译时间、编译器内存分配（GGC 自报）与目标文件体积三个口径，报告附完整复现命令。

结论	数量	含义
建议删除	1	编译通过且耗时下降超过噪声线
保留	187	编译器已否决或定位不到该注释哪一行
需人工判断	34	编译可行但收益在噪声内，全部附倾向

表：nlohmann/json 测试目标 222 个候选全部真实编译后的结论分布（experiments/decision_check.py，可一键复现）。唯一一条「建议删除」的三个维度全部实测：unit-windows_h 去掉 windows.h，编译 1610 ms → 910 ms（−43.5%）、GGC 内存 301,052 kB → 168,960 kB、目标文件 63,004 B → 62,972 B。体积那一行是阴性结果——收益全部在编译时间侧——这类数据与正向收益一样必须实测，不能省略。[D6]

四道门槛的实测结论（含两项部分通过）

项目按预注册判据跑了四道门槛，结果写在正文而不是附录里。G1 公平对照：部分通过——与 ClangBuildAnalyzer 在同一批 25 个编译单元、同一编译器、同一候选规则下对照，口径统一后 Top-10 重合 7/10、Spearman ρ ≈ 0.68，只能说明中度一致，不能说明我们更准。G2 优化闭环：成立但有限，且经历了完整一轮「不利数据 → 迭代 → 重跑验证」——第一版协议是 0/10，拆开看有三个来源：候选空间只覆盖编译单元自己的 include（83 条里仅 3 条疑似未使用）、测量协

议把机器漂移整块算成收益（聚合 A/A 2.005%，改成交替后 0.644%）、以及「#include <regex>」这一行的文件名污染了用法判定使结论恒为「在用」。逐个修掉后的首轮全量探测（2026-10-18）给出诚实基线：doctest 1/16、zlib 关闸门后 1/16、json 0；三档探测（16 条 50%、19 条 53%、66 条 47%）说明闸门对「能否编译」没有预测力，它省的是候选数量。这组不利数据随后成为迭代起点：围绕「为什么那 1 条要碰运气才找到」，四轮候选判定精度专项（供给者唯一性、副作用型 include、集合语义的别名链、命令行宏的条件分支求值）把三个语料的「疑似未使用」判定做到零假阳性；同协议重跑（2026-10-19）：真优化从第 2 位升到第 1 位、闸门内候选 16→13、编译通过率 50%→62%、采纳率 1/13，zlib 那条真优化变成闸门直接命中；新语料 spdlog 的 TU 层候选按新排序取前 3 条送计时闭环，其中 −77.8%（三次独立复现）的大额收益经第五轮汇编闸门复核，实为静默改程序（删掉的是公共 API 的实现，见下）——计时口径与反事实口径的差异正是本研究方法的核心。注入-召回 2/2 命中（头文件级排 1/17、单元级排 25/61，各两遍独立运行均过线）。诚实的边界也有实测样本：一个格式化 std::vector 的候选被文本层判可删、实测编译失败（收益由重载决议选中的模板实例化提供，源码无唯一指向标识符）——AST 区误判由 verify 实测拦截，这是最终防线。「命中率低是不是工具不行」用失败原因分类回答（第五轮，四语料 100 TU）：把每条候选的结局分成七类并加测「被判在用」的镜像样本——推送集 26 条疑似未使用里仅 1 条判定漏判（零假阳性是准确），漏报 47 条但集中在两个可修点（UCRT 宏副作用误判、无法判定的保守层）且仅 1 条预估超0.1 秒；核心指标「分析时间 → 已证实优化」约 4.5 秒/条、每 100 TU 23 条。G3 门禁：成立但范围有限——注入回归 3/3 检出、无回归 3/3 通过、构建损坏 3/3 拦截，单次 3.38 秒；盲区是「行数不变但编译变慢」的回归测不出。G4 工程开销：成立——扫描开销为纯编译的 1.15×（GCC）/ 1.20×（Clang），峰值 9.2 MB，三次运行结果一致。四条合起来，产品承诺收窄为：不替你找到优化，而是把「看起来能省」变成「确认能省 / 确认不能省」，并固化成能拦住回归的基线。迭代前后的实测变化：doctest 采纳率 1/16 → 1/13、真优化第 2 → 第 1 位、编译通过率 50% → 62%；zlib 那条从「关闸门才找到」变成闸门直接命中；「疑似未使用」三语料零假阳性。json 的 0 与 AST 区误判样本如实列出，都有可复现数据。

门禁：失败时指名道姓

```
$ heavyheader gate ./src --baseline baseline.json --max-regression 5
头文件解析量：206,100 -> 241,300 (+17.1%)
门禁失败：
- header cost regressed +17.1% (206100 -> 241300 attributed lines), budget is +5.0%
worst offender: include/bloated.h 0 -> 22312 lines (+100.0%)
```

一个只说「成本回归 +12%」的门禁毫无用处；能定位到具体头文件与 include 行的门禁才会被留下来。失败信息直接给出最严重的回归者及其前后行数，构建日志里的每一个人都能立刻知道该找谁、改哪里。

四 成本归因如何保持准确

归因行数：定义与局限

归因行数 = 头文件行数 × 引用它的编译单元数。C++ 项目的预处理与解析成本一阶近似正比于「编译器被迫读了多少头文件文本」，每个被解析的头文件在每个引用它的编译单元里贡献一次自己的行数。这个指标对同一份代码是确定性的，因此适合作为门禁判定依据。它的局限同样明确：行数不等于解析难度，一个 100 行的重型模板头可能比 1000 行的纯声明头更慢——它是相对排序指标，不是绝对耗时的预测器。[D1]

独占闭包：与 lint 工具的本质区别

删掉一条 include 之前必须回答：这个头文件还能不能从别的 include 到达？如果能，删掉当前这条并不会让它停止被解析——钱已经花了。独占闭包定义了删掉某条直接 include 后唯一会停止被解析的头文件集合，只有它才是真实收益。实现上有一个值得记录的真实 bug：早先版本把候选自身也放进了「已付费」并集，导致每个候选的独占集合恒为空，于是所有项目都报告「没有可优化项」——这个症状与「确实没问题」在输出上完全无法区分，因此靠单元测试而非代码审查防守。[D1][D5]

重复解析检测：唯一的「必赚项」

-H 只为编译器实际处理过的包含打印一行，带 guard 的头文件在同一编译单元内物理上不可能出现第二次。因此「同一编译单元内出现多次」必然意味着缺少 include guard，修复（补 #pragma once）永远安全且收益立竿见影——这是全部发现里唯一标注为必赚项的分类。[D1]

模板实例化成本与实测方法学

-ftime-report 从 GCC 9 起报告各阶段耗时，对模板重型 C++，「模板实例化」常是最大单项——实测全项目模板实例化占构建时间 23%–32%（两次独立扫描，随负载波动）。每个编译单元的秒数与占比是精确的；把它按头文件分摊是启发式，报告内明确标注。verify 侧的方法学：注释而非删除、临时目录重编并补上原文件所在目录的 -I（#include "..." 相对于包含它的文件所在目录解析）、每侧重复 N 次取最小值——噪声只会让测量变慢不会变快，最小值是最接近真实成本的估计；相对差异低于 2% 视为噪声地板，把 1% 的波动报告成优化成果是不诚实的。R2：GCC 调试选项文档 [D1]

门禁判定公式

```
regression = (attributed_lines_after - attributed_lines_before)
/ attributed_lines_before * 100%
fail if regression > max_regression_percent (默认 5%)
```

默认 5% 刻意保守：在噪声上误触发的门禁会被关掉，而关掉的门禁保护不了任何东西。5% 是「明显变化」与「正常波动」之间的实用分界。[D1]

五 真实项目基准

基准覆盖四个真实开源项目，由 benchmarks/run_all.py 一键生成，每个项目的编译 flags 都是实际跑通、能产出干净数据的那组并记录在案。数据取自 GCC 16.2.0 (MinGW-w64) + Python 3.13，54 个成功编译单元。[D3]

项目	编译单元	依赖边	头文件解析量	成本候选	疑似未使用
fmt	3 成功 / 1 失败	651	331,016	7	0
nlohmann-json	25 成功 / 0 失败	9,294	4,866,676	53	0
spdlog	8 成功 / 17 失败	3,246	1,579,902	26	3
cpp-httplib	18 成功 / 7 失败	14,724	7,523,316	18	0
合计	54 成功	27,915	14,300,910	104	3



图 2 四个真实项目的头文件归因解析量（行）。cpp-httplib 的单体头 httplib.h 一项即被归因 42 万行解析量。数据来源：benchmarks/results/summary.md，可一键复现。

代表性成本热点

项目	头文件	行数	引用 TU	归因行数
nlohmann-json	json.hpp	8,177	24	196,248
cpp-httplib	httplib.h	23,343	18	420,174
spdlog	fmt/bundled/format.h	4,395	8	35,160
fmt	format.h	4,709	2	9,418

读这些数字时要注意四件事。第一，失败的编译单元被如实报告，没有为了凑数字跳过——真实项目常需 CMake 生成的配置头才能编译，本机没有 CMake，spdlog 的 17 个失败单元与 cpp-httplib 缺 OpenSSL 头的 7 个失败单元都写在报告顶部。第二，具体数字随编译器版本、平台、负载变化，不应逐位复现；可复现的是结论方向与数量级。第三，候选清单包含系统头——删除动作发生在项目自己的源文件里；早先版本排除系统头，恰好挡掉了全部有效改动。第四，「疑似未使用」是启发式排序信号而不是安全性结论，权威判定来自 verify：真的删掉、重新编译，并给出明确结论（见第三章）。本组数据里仅 spdlog 报出 3 条疑似未使用，全部集中在 TU 层；它们随后的去向演示了三态结论的完整闭环——1 条实测 improved（聚合 566 → 125 ms，三次独立运行复现）、1 条在噪声线边缘（+2.4%~2.9%）、1 条实测编译失败（AST 区的模板实例化依赖，verify 拦截）。其余三个工程 0 条——成熟项目的 include 大多是干净的，工具没有为了凑数字而喊。[D3]

换更大的语料：判据差的不是精度，是按配置求值

前四个工程用来做精度专项（候选判定对不对）。要回答「绝对值有多少」，只能换更大的真实工程，于是语料扩到五个：doctest、zlib、Lua 5.4.7、zstd 1.5.6、brotli 1.1.0。后两个是规模检验——zstd 的 lib/ 有 39 个编译单元、351 万行头文件解析量，是 Lua（34 TU / 109 万行）的 3.2 倍；brotli 有 32 个编译单元、295 万行。[D3]

语料	编译单元	头文件解析量	基线	本轮用它回答什么
doctest / zlib / Lua 5.4.7	149 / 9 / 34	—	—	候选判定精度与假阳性
zstd 1.5.6（lib/）	39	351 万行	40.5–53.4 s	单条收益的绝对值上限
brotli 1.1.0（c/）	32	295 万行	45.0 s	代码组织方式的特殊结构

zstd 首轮同时给出一个好消息和一个坏消息。好消息：最大的一条候选 `pool.c → allocations.h` 实测 384 → 205 ms（−46.5%），解析文件数 184 → 32，是全项目至今最大的单条收益。坏消息：7 条「疑似未使用」候选实测收益全为 0，而真正有收益的那条被判成「在用」。根因不是判据不够精细，而是判据没有按配置求值——相关引用全部落在 `#ifdef ZSTD_MULTITHREAD` 区间里，这批编译命令没有定义那个宏。

这次修复换来一句可以直接引用的话：同一行 include，在两种构建配置下答案相反。同一棵源码树，不加宏时删掉它能编过且汇编一致；加上 `-DZSTD_MULTITHREAD` 之后删了直接编译失败。「这条 include 该不该删」不是源码的属性，是构建配置的属性。这一条现在是一条命令：`heavyheader configs` 把同一份 compile_commands.json 派生几份、各扫一遍、按（单元, 头, 行）对齐，只报判定变了的候选——zstd 三套配置扫下来是 90 / 91 / 93 个候选，只有 3 条判定不同，方向全部手工编译核对过。

brotli 暴露的是另一种结构：它用无 include guard 的实现片段组织代码（先 `#define FN` 再 `#include`），片段里的代码不在编译单元的文本里，于是「片段用到了这个头的符号」在文本层根本不存在。修法是承认这种结构，并区分重复包含的两种性质：带 guard 的头第二次起是空操作（删任何一行都不省解析，收益按 0 计）；无 guard 的片段每次包含都是一次实例化，展开成 N 条站点候选、强制过汇编闸门。brotli 上 31 个站点实测 0 条可删——28 条编译失败、3 条汇编指纹变了；关掉强制闸门时，那 3 条会退化成「无变化（−8 ms）」，也就是看起来无害的破坏性改动。

六 CI 门禁与治理流程

从一次性分析到持续治理

单次扫描的价值随时间衰减：报告生成那一刻起，代码就在继续变化。因此平台把「基线快照 + 回归门禁」作为与扫描同等的一等能力。治理流程是：在干净状态扫描并保存基线；此后每个 PR 在 CI 里重新扫描并与基线对比；归因行数回归超过阈值（默认 5%）则流水线失败，失败信息指名道

姓。compare 命令支持对任意两份扫描结果做同样的事，用于事后定位「构建什么时候变慢的」。

为什么门禁只用确定性指标

墙钟时间随机器、负载、时钟状态波动，是最吵的数字。gate 不用它做判定依据，只做展示；跨机器、跨时段不比较绝对值。判定依据只有归因行数——它对同一份代码是确定性的，同样的输入必然给出同样的数字，这是门禁可信的前提。趋势图里墙钟时间与归因行数一起画，但归因行数是主指标。[D1]

七 诚实的边界

这个工具不做什么，和它做什么同样重要。以下每一条都是设计决定而非能力缺口，均有对应的理由与替代方案。[D8]

已知局限	含义与对策
不判定 include 是否「未使用」的语义真相	文本启发式会被副作用包含（如 iostream 的流初始化）误判；权威结论来自 verify 实测
前向声明建议：文本候选需实测裁决，实测本身也未必有候选	「只以指针/引用形式使用」是语义属性，正则可能被宏、typedef、模板参数欺骗；报告给出类型名、行号与阻断类型供人确认，forward-verify 再把改动真做一遍、用汇编指纹判定等价性。三个真实语料上候选数均为 0——模板实参（shared_ptr<T>）与 auto 都不匹配判据，所以这条能力的价值是「把建议钉死在证据上」
不做精确的 AST 级分析	精确模式需要 libclang 全套工具链，与零依赖部署约束冲突；排在 v0.3 作为可选依赖
verify 不改写用户代码	实验只在临时目录进行，原始文件一个字节都不会动
不跨机器比较绝对耗时	墙钟时间随负载波动；门禁只对比确定性的归因行数与相对比例
-fsyntax-only 不含代码生成阶段	报告默认不含 opt 与 generate 的成本；--full-compile 可包含但扫描明显变慢
ccache 环境下 verify 需先清缓存	否则测到的是缓存命中时间而不是编译时间

「可采纳率」是三个指标，引用时必须带分母——这一点单独说明，因为它最容易被读错。① 池内采纳率 25%（5/20）：只回答送测池里多少条最终被确认为 improved，不是端到端准确率，也不是召回率；② 产出速度 52 秒/条：扫描 + 三真值 + 计时漏斗 4 分 21 秒换 5 条（修复前是 4.4 分钟/条）；③ 端到端 2.3%（5/222）：相对「真能删 69 条」是 7.2%。同一池换一种测量协议（双侧预热 + min-of-5）得 40%，成员只重合 3 条——率是协议的属性，不只是工具的属性。[D3]

还有三条必须一起读的限定：单侧 5 次读数的极差中位数是 11.8 ms，而确认收益只有 2.7–8.8 ms，收益是 min-of-N 压出来的；复测存活率 73%（11 → 8）；49 条未送测的已证实候选确实少解析 2,374 行，只是低于噪声线 3–5 倍——不可说成「工具对它们没有潜在收益」，只能说这台机器上测不出来。同理，「已验证层级」（汇编一致 + 省时过线 + 复测成立的候选）也不是一张稳定名单：Lua 上同一命令连跑两遍，进这一层的分别是 2 条与 3 条，成员零重合。它只对「本轮」负责。

[D3]

方法论文档为报告里的每一个指标给出定义：「如果一个指标没法在这里查到定义，那它不应该出现在报告里。」[D1]

八 报告与可复现

三种格式，一份数据

scan 同时支持 Markdown（评审与 PR 评论）、HTML（自包含单文件，可直接分享或挂内网）与 JSON（供基线与后续工具消费）三种输出，全部渲染自同一份内部结果，不存在两套数字。
HTML 报告内嵌全部样式与数据，无外部资源引用，拷贝到任何机器都能打开。

基准可一键重跑

benchmarks/run_all.py 一键重跑全部四个项目的基准并生成汇总。每个项目的 flags 都记录在基准脚本与结果说明里——写下来是为了下次能复现。compile_commands.json 存在时严格采用其中的编译命令，这是「同一份代码的数字可比」的保障。[D3]

九 技术路线与模块分工

分层结构

模块	职责
drivers/	向编译器提问：GCC / Clang / MSVC 各自的方言
parse/	解析 -H 依赖树、-ftime-report 计时、make 风格依赖文件
attrib/	成本归因：依赖图、独占闭包、重复解析检测、使用启发式
scanner.py	编排：发现编译单元 → 并行编译 → 汇总统计
verify.py	实测验证：注释掉、重编译、计时
baseline.py	基线、对比、CI 门禁
report/	Markdown / HTML（自包含单文件）/ JSON 渲染

几个刻意的设计选择

一次编译同时拿到依赖树、分阶段计时与 guard 缺失三项数据（-H 与 -ftime-report 都写 stderr，可并行收集）——第二次编译会让扫描耗时翻倍，更糟的是两次编译之间头文件若发生变化，两边数据会互相矛盾。扫描默认用 -fsyntax-only 而不是完整编译，换取数量级的速度提升；依赖图上的闭包计算迭代而非递归，喂给畸形输入时不会栈溢出。完整的取舍记录在架构文档里。[D2]

测试策略

725 个单元测试覆盖解析、归因、门禁、verify、增量缓存、多编译器对比与并行编译健壮性各子系统。测试样本优先用真实编译器输出逐字复制而不是手写构造——解析器的输入是编译器方言的文本，手写样本会悄悄偏离真实格式。上一节提到的独占闭包 bug 正是因为「症状与正常输出无法区分」，才以回归测试的方式永久防守。[D5]

真实工程上的完整构建实测

为避免「只有解析量、没有真实构建收益」的质疑，另做了一组可复现的对照实验：对象是 nlohmann/json v3.11.3 的测试目标（63 个编译单元，源码以 SHA-256 固定），两臂各 5 次干净构建。按工具的预编译头建议实施后，完整构建墙上时间中位数 43.2 s → 40.1 s（−7.1%），编译 CPU 292 s → 259 s（−11.4%），63 个测试套件的 4,264,414 条断言逐个一致。[D4]

估算与实测分开陈述、从不合并：工具估算「消掉 91.2% 的头文件解析量」（按行计，是上限），实测是「编译 CPU −11.4%」（按秒计）。由二者反推，头文件解析约占编译 CPU 的 17%——这正是「估算 91% 落地为实测 11%」的原因，也是不能把估算当秒数引用的理由。[D4]

同一实验还给出了一条对工具不利的结论，第一版报告里照实写了：在「逐个删 include」这件事上，按调用频次排序的经验法则 12 次试验命中 3 个有效改动，而工具按收益排序的5 个候选全部编译失败。[D4]

事后复核发现，这句话里有一半不是工具的错，是测量的错：那一版的基线用 8 路并行测量、每次试验却单独编译，基线被 CPU 争抢抬高约 25%。把那三个「有效改动」串行复测，结果是 +0.4% / −1.1% / −0.1%——即全是噪声。修正协议后（基线串行、每次试验 3 次取最小、并用 A/A 空对照现场量出噪声底来定阈值）重跑，两个策略都没能在这个工程里找到站得住的单点删除收益。[D4]

另一半确实是工具的错，共三处结构性缺陷，均已修复：① 用法判定只看候选头自己那段文本，而删掉一行真正消失的是它往下拉的整批头——TEST_CASE 在 doctest.h 里、不在 doctest_compatibility.h 里，于是 5 个候选全被判成「没人用」；② 按「全项目可省行数」排序，收益最大的头正是最不可能可删的，它排第一；③ 候选池直接排除了系统头，而编辑动作发生在自己的源文件里，系统头同样可提议。[D4]

修复后的排序改为「可采纳性优先」：先按结论分层（建议删除 / 需人工判断 / 保留与已证伪），层内再按本单元预计省下的秒数排。用一个零构建试验的回顾性检验背书——拿实验里已实测的 17 个结局当答案，只看新排序怎么排：13 个已知失败候选全部被压后，已知可删的 unit-bjdata/iostream 从「根本不在候选空间」升到第 3 名。[D4]

但这里必须把边界说清楚，否则就是把修好的排序又吹大了：扫描排序的意义是少花构建试验，不是替代构建试验。「这一行能不能删」的最终判定只能来自真的编译一次——verify 做的正是这件事（注释掉那一行、重编、测时间）。所以报告里的口径是：估算归估算、实测归实测、证伪归证伪，三栏从不合并。[D4]

十 已有基础与开发起点

当前可以接着做什么

项目不是一个构想：v0.1–v0.4 路线图全部条目已完成，代码以 Apache-2.0 许可证公开在 github.com/wzzrambler/heavyheader，283 个文件、工作区无未提交改动，v0.1.0 已发布至 PyPI 并通过全新虚拟环境安装验证。下表按「已有基础 / 已核对的内容 / 接下来的开发工作」汇总。[D4]

已有基础	已经核对的内容	接下来的开发工作
十一命令 CLI（scan / verify / verified / gate / compare / history / pr-comment / toolchains / blame / edge-cost / configs）	终端输出样例与 725 个单元测试	pr-comment 的 GitLab 后端仍待做（需另一套 API）
三编译器驱动（GCC / Clang / MSVC）	四真实项目基准，54 个编译单元的采集记录	toolchains 与 blame 的多语言输出细节打磨
增量扫描（--cache）	文件指纹两级判定；已验证增量结果与全量逐字一致	多人共享的趋势服务仍待做（需持久化存储与多端访问）
三种报告格式与自包含 HTML	HTML 单文件在无外部资源下可打开	按头文件分别设预算：单个头也不许悄悄长胖
发布流水线与上游落地	v0.1.0 已发布至 PyPI（Trusted Publishing，全新环境安装验证通过）；两条实测优化已提交上游：doctest#1212、zlib#1344	跟进上游 PR 评审意见；按头文件预算、GitLab 后端等生态项

持续集成覆盖三大操作系统（ubuntu / windows / macos）× 四个 Python 版本（3.10–3.13），fail-fast 关闭以保证每个组合都被完整验证。self-scan 任务在 CI 里构造一个真实 C++ 工程（带重复包含、重量级闭包与缺 guard 的头文件）并用 HeavyHeader 扫描、跑门禁——这是在非 Windows、非 MinGW 的工具链下验证解析正确性的集成测试。[D5]

十一 同类工具与项目价值

定位差异

与同类工具相比，HeavyHeader 不试图替代它们，而是补上它们共同缺席的一层：成本。IWYU 仍然是最精确的「该不该删」判定者；HeavyHeader 回答的是「删了值不值、先删哪个、删完怎么守住」。更准确地讲，它换掉的是范式：竞品输出排序（Header Hero、ClangBuildAnalyzer）、清单（IncludeGuardian）、二值验证（deheader）或语义判定（IWYU、clang-include-cleaner）； HeavyHeader 输出的是反事实实验的结论——「删掉这行的净收益是多少、有多大把握、凭什么信」。这个位置在本轮竞品尽调里是空的。

能力	IWYU 等结构分析工具	HeavyHeader
include 必需性判定	精确（AST 级）	启发式 + verify 实测兜底

能力	IWYU 等结构分析工具	HeavyHeader
成本量化与排序	无	归因行数 + 分阶段计时
删掉的预期收益	无	独占闭包精确到头文件集合
实测验证	无	注释-重编-计时，min-of-N
CI 门禁	无	基线 + 阈值回归判定
部署门槛	需 LLVM 工具链	源码安装，零第三方运行时依赖

项目希望验证的价值主张是：把「头文件成本」从开发者的直觉变成工程数据之后，构建效能治理可以像测试覆盖率一样被持续度量与门禁把守。这一主张已经落到具体场景：nlohmann/json 63 个编译单元的完整构建对照（墙上 −7.1% / 编译 CPU −11.4% / 4,264,414 条断言逐个一致），以及把两条经复测的优化（doctest −3.01%、zlib −2.125%）提交为上游 PR（doctest#1212、madler/zlib#1344；截至 2026-10-21 均为 open、未被合并）——场景落地的终点不是实验报告，是真实工程真的接受这个改动。同任务工具对照（竞品在同工程同任务上 0 条删除建议、我们 1 条实测 −43.5%）与三个工程的采纳率（首轮 1/16、1/16、0/16，四轮迭代后重跑为 1/13 且真优化排第 1）全部公开，方法见方法论文档。[D1]

十二 团队协作与后续开发

申报与协作模式

本项目以开源社区主体类型（个人）申报第四届开放原子大赛·2026 开源行业解决方案创新赛赛道一。项目采用标准的开源协作模式：Issue 报告缺陷与需求、PR 贡献代码、CONTRIBUTING 说明「什么类型的贡献最被需要」、行为规范与安全披露流程齐备。Apache-2.0 许可证对贡献者与使用者都明确，含专利授权条款，且与生态中大量 C++ 项目的许可证兼容。[D7]

后续开发路线

v0.2「从工具到平台」聚焦团队持续使用：本地历史趋势看板、PR 评论机器人（GitHub）、多编译器对比（GCC / Clang / MSVC）均已交付；剩余多人共享的趋势服务（需持久化存储）、GitLab 后端。v0.3「精确模式」用 clang-include-cleaner 外部进程做可选 AST 交叉检查（只增强、不削弱）。文本层的候选判定已经过四轮精度专项迭代——三个语料（doctest / zlib / Lua）的「疑似未使用」推荐零假阳性；AST 交叉检查补的是文本层原理上看不到的那一类（重载决议选中的模板实例化，实测样本在 spdlog 上），结论形态（建议删除/保留/需人工判断）与三维度实测框架已经就位。默认路径保持零依赖不变。v0.4「精度引擎」已交付（成本考古 blame、边级归因 edge-cost）；v0.5「生态集成」进行中：PyPI 已于 2026-10-19 上架（v0.1.0），CMake / Bazel / Meson 适配、VSCode 插件、IWYU 输出互转进行中。排序即优先级，完整路线图见仓库。[D4]

治理与社区

治理结构写在 `GOVERNANCE.md`：维护者、贡献者阶梯（报告 Issue → PR → 分诊 → 共同维护者）、决策流程（常规 PR 一人审阅；破坏性变更先开 Issue）、发布纪律（语义化版本 + tag 触发 + CHANGELOG 先行）与依赖政策（零运行时依赖是 CI 守护的架构约束，不是口号）。长期发展路径：v0.5 稳定后申请加入开源基金会孵化体系，让治理从「一个人」演进为「一个社区」。

比赛节点

作品材料（介绍文档 PDF、演示视频、代码仓库）于 2026 年 10 月 31 日 24:00 前提交；11 月 6 日公布入围名单；11 月 13 日总决赛线下路演。当前仓库即评审可见状态，评审期间仅修复缺陷、不引入新功能，保证评委看到的与提交时一致。[D7]

参考资料

外部资料均为原始发布页面或官方文档，访问核对日期为 2026 年 10 月 16—19 日。

· R1 GCC, Preprocessor Output（-H 选项：打印被实际处理的头文件）。
https://gcc.gnu.org/onlinedocs/gcc/Preprocessor-Output.html

· R2 GCC, Debugging Options（-ftime-report：编译各阶段计时）。
https://gcc.gnu.org/onlinedocs/gcc/Debugging-Options.html

· R3 Microsoft, /showIncludes (List Include Files)。
https://learn.microsoft.com/cpp/build/reference/showincludes-list-include-files

· R4 include-what-you-use 项目主页。https://include-what-you-use.org/

· R5 Header Hero（Bitsquid, 2011）：归因行数与 Blowup Factor 的出处。
https://bitsquid.blogspot.com/2011/10/caring-by-sharing-header-hero.html

· R6 aras-p/ClangBuildAnalyzer：逐头文件累计耗时（-ftime-trace）。
https://github.com/aras-p/ClangBuildAnalyzer

· R7 Viladoman/CompileScore：同一数据源的 VS 内可视化。
https://github.com/Viladoman/CompileScore

· R8 Microsoft C++ Build Insights：include 树与 PCH 建议。
https://learn.microsoft.com/cpp/build-insights/get-started-with-cpp-build-insights

· R9 IncludeGuardian：七类结构建议。https://includeguardian.io

· R10 deheader（Eric S. Raymond）：注释掉再编译。https://catb.org/~esr/deheader/

· R11 lukedodd/include-wrangler（2012）：按文件数的边级边际成本。
https://github.com/lukedodd/include-wrangler

· R12 DmitriBogdanov/clang-build-profiler：include 树逐边解析耗时。
https://github.com/DmitriBogdanov/clang-build-profiler

· R13 chrisburr/include-what-costs：逐头文件实测耗时与内存。
https://github.com/chrisburr/include-what-costs

· R14 nlohmann/json 仓库（基准对象之一）。https://github.com/nlohmann/json

· R15 yhirose/cpp-httplib 仓库（基准对象之一）。https://github.com/yhirose/cpp-httplib

· R16 开放原子开源基金会，开放原子大赛信息页。https://www.openatom.org

项目设计与实测依据

项目内文档按主题列出，全部随公开仓库提交，详细方法、接口与试验记录可供评审查证。

· D1 docs/methodology.md：《方法论：这些数字是怎么算出来的》——全部九个指标的定义与局限。

· D2 docs/architecture.md：《架构》——分层结构、数据流与六个刻意的设计选择。

· D3 benchmarks/：run_all.py 基准脚本与 results/summary.md 汇总——四个真实项目的实测数据。

· D4 ROADMAP.md：《路线图》——v0.1 / v0.2 / v0.3 排序即优先级。

· D5 tests/：725 个单元测试，样本优先采用真实编译器输出逐字复制；按平台中性编写。

· D6 experiments/results/decision-20261018.md：《删除建议决策层实测》——222 个候选全部真实编译后的结论分布、三维度数据与竞品交叉核对。

· D7 SUBMISSION.md：《提交清单》——比赛材料、节点与剩余步骤。

· D8 README.md：项目主页——能力总览、诚实的边界与快速开始。

· D9 .github/workflows/：ci.yml（三系统 × 四 Python 版本测试 / lint / self-scan）、coverage.yml（覆盖率）、msvc-evidence.yml（MSVC 真实运行证据）、release.yml（tag 触发发布）。

· D10 docs/innovation.md：《独创性说明》——反事实构建实验范式、三项创新点、消融表与不声称清单。

· D11 docs/scenario.md：《场景落地》——四步全链路、真实工程数据卡与复现入口。

· D12 GOVERNANCE.md：《治理结构》——角色、决策流程、发布纪律与依赖政策。

· D13 contrib/upstream/：《上游落地战役》——两条 PR 已提交：doctest#1212、madler/zlib#1344（含补丁与英文正文）；2026-10-21 核实状态均为 open、未被合并。